

视觉大模型在智慧校园行为智能分析中的应用研究

十日实施计划

中国石油大学（北京） 计算机科学与技术 2023 级

2026 年 10 月

1 项目定位

本项目聚焦**教室 / 图书馆**场景下的学生行为智能分析，使用百度千帆平台上的 **Qwen3-VL-32B-Thinking** 视觉大模型，以**自然语言描述行为规则**的方式实现零样本行为识别，并与传统 YOLO + 规则方法做对比。

目标识别的 5 类行为：

1. 长时间趴桌睡觉 (>30 s)
2. 持续看手机 (>30 s)
3. 频繁左右回头张望
4. 两人及以上持续交谈
5. 离座长时间未归

核心创新点（一句话讲清楚）：传统行为识别需要为每种行为单独标注数据并训练模型；本项目用视觉大模型，只需用自然语言描述新行为规则即可识别，**换一种行为不用重训模型**。

2 技术路线与模型选型

数据流向：视频 → 抽帧 (1 fps) → YOLOv8 检测人体并裁剪 → Qwen3-VL 逐帧判断 → 事件聚合 → 时间轴 + 告警报告。

3 仓库目录结构

```
Research-Training-Program/  
  docs/
```

千帆平台模型	在本项目中的角色
Qwen3-VL-32B-Thinking	核心视觉推理引擎：输入裁剪后人体帧 + 行为规则 prompt，输出结构化 JSON
DeepSeek-R1-Distill-Qwen-32B	事件聚合：把逐帧判断聚合成事件、生成告警文案
Qwen3-VL-Embedding-8B	关键帧向量化，检索历史相似事件（可选项，时间不够可砍）
Jina-Embeddings-V3 + Bce-Reranker	RAG：把课堂纪律条款切片入库，告警时匹配对应条款（可选项）
YOLOv8（本地）	Baseline 对比方法 + 视频中人体检测预处理

```
project_plan.tex          # 本计划
src/
  config/config.yaml      # 千帆 API Key、模型名、路径
  data/
    raw/                  # 原始视频
    frames/               # 抽帧结果
    crops/                # 人体裁剪图
  preprocess/
    extract_frames.py     # 视频抽帧
    detect_persons.py     # YOLOv8 人体检测与裁剪
  vlm_infer/
    client_qwen_vl.py     # 千帆 SDK 封装
    prompts.py            # 行为规则 prompt 模板
    run_inference.py      # 批量推理主脚本
  aggregate/
    events.py             # 连续帧聚合成事件
  baseline/
    yolo_rules.py         # 传统方法 baseline
  app/
    demo.py              # Streamlit 演示界面
results/
  json/                  # 逐帧推理结果
  events/                 # 聚合后事件
  report/                 # 最终报告
README.md
```

4 十日计划总览

Day	阶段	核心任务
1	环境打通	千帆 API 调通 Qwen3-VL，跑通第一张测试图
2	预处理	视频抽帧 + YOLOv8 人体检测裁剪
3	数据准备	自录 5 类行为样本 + 标注时间区间
4	Prompt 工程	设计行为规则 prompt，让 VLM 稳定输出 JSON
5	批量推理	对全部视频帧批量跑 Qwen3-VL
6	事件聚合	连续帧合并为事件，抑制误报，画时间轴
7	Baseline 对比	YOLOv8 + 规则方法跑同一份数据，对比指标
8	Demo 系统	Streamlit 界面：上传视频 → 行为时间轴 → 报告
9	文档撰写	技术报告、答辩 PPT、README
10	测试收尾	全流程复跑、整理代码、Git 提交

5 每日任务详解

Day 1 —环境与 API 打通

- 在千帆平台申请 API Key，记录 API_KEY、SECRET_KEY。
- 创建虚拟环境，安装依赖：openai（千帆兼容 OpenAI SDK）、opencv-python、ultralytics、streamlit、pyyaml。
- 编写 client_qwen_vl.py：封装一个函数，输入「图片路径 + prompt」，输出 VLM 返回文本。
- **验收：**用一张随手拍的教室照片提问「图里有几个人？他们在干什么？」，能拿到自然语言回答。

Day 2 —视频预处理流水线

- extract_frames.py：按 1fps 抽帧，按 视频名/frame_0001.jpg 组织。
- detect_persons.py：加载 YOLOv8 (yolov8n.pt 即可)，检测 person 类别，按 bbox 裁出人体，加 10% padding 存入 crops/。
- **验收：**拿一段 30 秒测试视频跑完，crops/ 里能看到清晰的人体裁剪图。

Day 3 —数据准备

- 找一间空教室，请 2-3 位同学配合，每类行为拍 5 段短视频（每段 30-60 秒）。
- 录制清单：趴桌睡觉、低头看手机、左右张望、两人交谈、离座。
- 每段视频人工记录「行为标签 + 起止秒数」，存成 data/annotations.csv：

```
video_id, behavior, start_sec, end_sec, note
v01, sleeping, 5, 40, normal sleeping
v02, looking_phone, 10, 55, ...
```

- 可选：补充 1-2 个公开教室行为数据集片段（如 Classroom Behavior Detection）。
- **验收**：至少 25 段带标注视频，覆盖全部 5 类行为。

Day 4 —Prompt 工程

- 设计行为规则 prompt 模板 prompts.py：

你是一个教室行为分析专家。请观察这张教室里的人像图片，判断以下行为是否正在发生，必须严格输出 JSON：

```
{
  "sleeping": 0/1,          // 是否趴桌闭眼睡觉
  "looking_phone": 0/1,     // 是否低头看手机
  "looking_around": 0/1,    // 是否频繁左右张望
  "talking": 0/1,           // 是否在与他人交谈
  "reason": "一句话说明判断依据"
}
```

不确定时对应字段填 0，不要臆测。

- 拿 10-20 张样本图人工测试，迭代 prompt 直到输出稳定为合法 JSON。
- **验收**：连续 20 次调用都能被 json.loads 正确解析。

Day 5 —批量推理

- run_inference.py: 遍历 crops/, 逐张调 Qwen3-VL, 结果追加到 results/json/<video_id>.json 每行：

```
{"frame": 12, "timestamp_sec": 12.0, "behavior": {"sleeping": 0,
  ...}, "reason": "..."}

```

- 控制并发与重试；API 失败要能断点续跑（已存在的 frame 跳过）。
- **验收**：所有视频帧跑完，结果落盘，可统计每类行为在每段视频里的帧数。

Day 6 —事件聚合与后处理

- `events.py`: 滑动窗口聚合, 连续 $N = 5$ 秒 (或 5 帧) 同标签才记为一个事件。
- 过滤过短事件 (< 3 秒), 抑制 VLM 偶发误报。
- 输出 `results/events/<video_id>.json`:

```
[{"behavior": "looking_phone", "start": 10.0, "end": 48.0, "confidence": 0.83}]
```

- 画一张时间轴图 (matplotlib 横条), 按行为着色, 人工目视检查是否合理。
- **验收**: 3 段测试视频的事件列表与人工标注基本吻合 (误差 < 5 秒)。

Day 7 —Baseline 对比实验

- `baseline/yolo_rules.py`: 用 YOLOv8 + MediaPipe 姿态关键点写简单规则:
 - 头相对肩膀角度 $> 45^\circ$ 且持续 $\Rightarrow$ 睡觉;
 - 手抬到脸附近 + 人脸不可见 $\Rightarrow$ 看手机 (粗规则);
 - 其余行为类 baseline 无法识别, 记 N/A。
- 在同一份测试集上统计两类方法的 Accuracy / Recall / F1。
- 做成对比表 (结果写进报告)。
- **验收**: 有一张清晰的对比表, 能说出 VLM 方法在哪些类上明显优于规则法。

Day 8 —演示系统

- `app/demo.py` 用 Streamlit:
 - 左侧上传视频;
 - 中间显示处理进度与当前帧;
 - 下方显示行为时间轴 (hover 显示 reason);
 - 右侧输出事件列表与自然语言报告。
- 可选: 接 DeepSeek-R1 把事件列表生成一段中文小结。
- **验收**: 双击 `streamlit run app/demo.py` 能完整跑通一段视频。

Day 9 —文档与报告

- 技术报告结构: **绪论** (背景、意义、国内外现状) $\rightarrow$ **方法** (系统架构、Prompt 设计、事件聚合) $\rightarrow$ **实验** (数据集、对比指标、结果分析) $\rightarrow$ **总结与展望**。
- 答辩 PPT 8–10 页: 背景、方法、架构图、关键结果、Demo 截图、总结。
- 写 README.md: 项目介绍、环境安装、一键运行命令、目录结构。
- **验收**: 报告初稿 + PPT 初稿完成。

Day 10 —测试收尾

- 在干净环境复现：按 README 从零安装依赖、跑通一段示例视频。
- 清理临时文件、敏感信息（config.yaml 里的 Key 改为环境变量读取，不要硬编码）。
- .gitignore 排除:data/raw/、data/frames/、data/crops/、results/json/、*.pyc、.env。
- Git 提交并 push:git add .; git commit -m "v1.0: 十日计划完成"; git push。
- 验收：GitHub 仓库可被他人 clone 后按 README 复现 Demo。

6 交付物清单

1. 可运行的代码仓库（GitHub: lingnaikelian/Research-Training-Program);
2. 至少 25 段带标注的教室行为视频样本;
3. 一份完整技术报告（Word / PDF);
4. 一份答辩 PPT;
5. 一个可现场演示的 Streamlit Demo;
6. VLM vs 传统方法的对比实验结果表。

7 风险与预案

风险		预案
Qwen3-VL 调用慢/贵	调用	降低抽帧率到 0.5 fps; 只把人体裁剪图（而非整帧）发给 VLM
VLM 把看书误判为看手机		Prompt 加区分特征; 事件聚合要求连续 5 秒同标签才报警
凑不齐 25 段视频		降到每类 3 段共 15 段也可, 重点是流程跑通
时间不够		Qwen3-VL-Embedding 检索、RAG 校规匹配是可选项, 10 天内做不完直接砍
本地无 LaTeX 环境		本.tex 上传 Overleaf 编译, 无需本地安装

后续每完成一天任务，在本计划对应小节后打勾并 push 一次 commit。